

V Coloquio de Psicología Fisiológica y
Experimental

Simposio

Inferencia Probabilística y Modelos Psicológicos

Laboratorio 25

Facultad de Psicología, UNAM

Proyecto PAPIIT: IN307214

Octubre 1º, 2014

Tutorial en Inferencia Probabilística

José Luis Baroja

Laboratorio 25

Facultad de Psicología, UNAM

Proyecto PAPIIT **IN307214**

¿Qué deberíamos creer sobre el mundo
después de recolectar ciertas
observaciones?

¿Qué deberíamos creer sobre nuestras
explicaciones/modelos sobre el
mundo **dadas** ciertas observaciones?

¿Qué tan probable es que nuestras **explicaciones/modelos** sobre el mundo sean correctos **dadas** ciertas observaciones?

$$Pr(\mathcal{M} \mid \textit{datos}) = ?$$

$$Pr(\mathcal{M} \mid \textit{datos}) = \frac{Pr(\textit{datos} \mid \mathcal{M}) Pr(\mathcal{M})}{Pr(\textit{datos})}$$

Teorema de Bayes

$$Pr(\mathcal{M} \mid \text{datos}) = \frac{Pr(\text{datos} \mid \mathcal{M}) Pr(\mathcal{M})}{Pr(\text{datos})}$$

Función de Verosimilitud



$$Pr(\mathcal{M} \mid \text{datos}) = \frac{Pr(\text{datos} \mid \mathcal{M}) Pr(\mathcal{M})}{Pr(\text{datos})}$$

**Función de
Verosimilitud**



$$Pr(\mathcal{M} | \text{datos}) = \frac{Pr(\text{datos} | \mathcal{M}) Pr(\mathcal{M})}{Pr(\text{datos})}$$

**Verosimilitud
Marginal**



Función de
Verosimilitud



Distribución
Prior



$$Pr(\mathcal{M} | datos) = \frac{Pr(datos | \mathcal{M}) Pr(\mathcal{M})}{Pr(datos)}$$



Verosimilitud
Marginal

Función de
Verosimilitud



Distribución
Prior



$$Pr(\mathcal{M} | datos) = \frac{Pr(datos | \mathcal{M}) Pr(\mathcal{M})}{Pr(datos)}$$

Distribución
Posterior



Verosimilitud
Marginal



Ejemplo:

¿Quién está en la fiesta?

M_1 : **Juan** está en la fiesta.

M_1 : Juan está en la fiesta.

M_2 : **El hermano** de Juan está en la fiesta.

M_1 : Juan está en la fiesta.

M_2 : El hermano de Juan está en la fiesta.

M_3 : **El amigo** del hermano de Juan está en la fiesta.

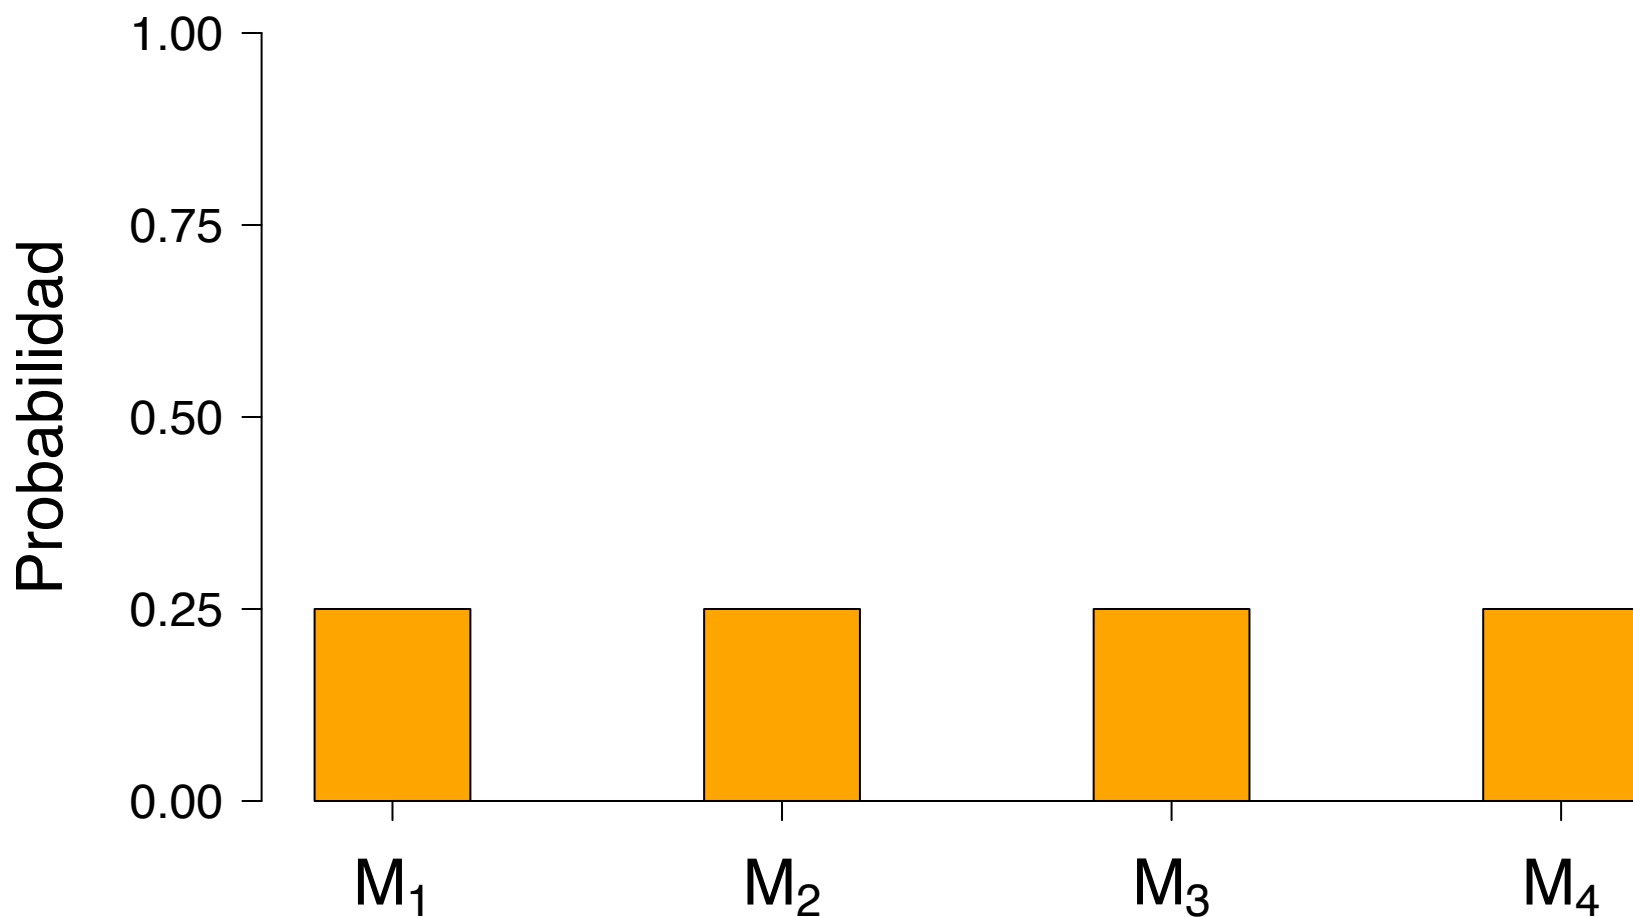
M_1 : Juan está en la fiesta.

M_2 : El hermano de Juan está en la fiesta.

M_3 : El amigo del hermano de Juan está en la fiesta.

M_4 : **Ninguno** de ellos está en la fiesta.


Distribución Prior: $\Pr (M_i)$



Evidencia:

**El auto de Juan está
afuera de la fiesta.**

Función de Verosimilitud: $\Pr (d \mid M_i)$




¿Cómo actualizamos nuestras
creencias después de observar la
evidencia?

¿Cómo actualizamos nuestras creencias después de observar la evidencia?

$$Pr(\mathcal{M}_i \mid d) = \frac{Pr(d \mid \mathcal{M}_i) Pr(\mathcal{M}_i)}{Pr(d)}$$


Distribución Posterior: $\Pr (M_i \mid d)$




(Otro) ejemplo:

¿Quién está en la fiesta **del amigo**?


(Otra) Distribución Prior: $\Pr (M_i)$



Función de Verosimilitud: $\Pr (d \mid M_i)$



(Otra) Distribución Posterior: $\Pr (M_i \mid d)$



La regla de Bayes especifica cómo
combinar **conocimiento previo**
con **evidencia nueva**.

Una moneda produce **soles** con cierta probabilidad desconocida θ .

Si observamos la secuencia:

00

¿Qué deberíamos creer sobre θ ?

Una moneda produce **soles** con cierta probabilidad desconocida θ .

Si observamos la secuencia:

00

¿Qué deberíamos creer sobre θ ?

¿Y si observamos?

0010100111010100101010101111

Una moneda produce **soles** con cierta probabilidad desconocida θ .

Si observamos la secuencia:

00

¿Qué deberíamos creer sobre θ ?

¿Y si observamos?

00101001110101001010101111

¿O si observamos?


0000000000001001000000000000

Secuencia 1:

```
X <- [ 0 0 ]
```


Secuencia 1:


$X \leftarrow [0 \ 0 \]$



$$X_i \sim \text{Bernoulli}(\theta)$$

Secuencia 1:

`X <- [0 0]`




$$\theta \sim \text{Beta}(\alpha = 5, \beta = 5)$$

$$X_i \sim \text{Bernoulli}(\theta)$$

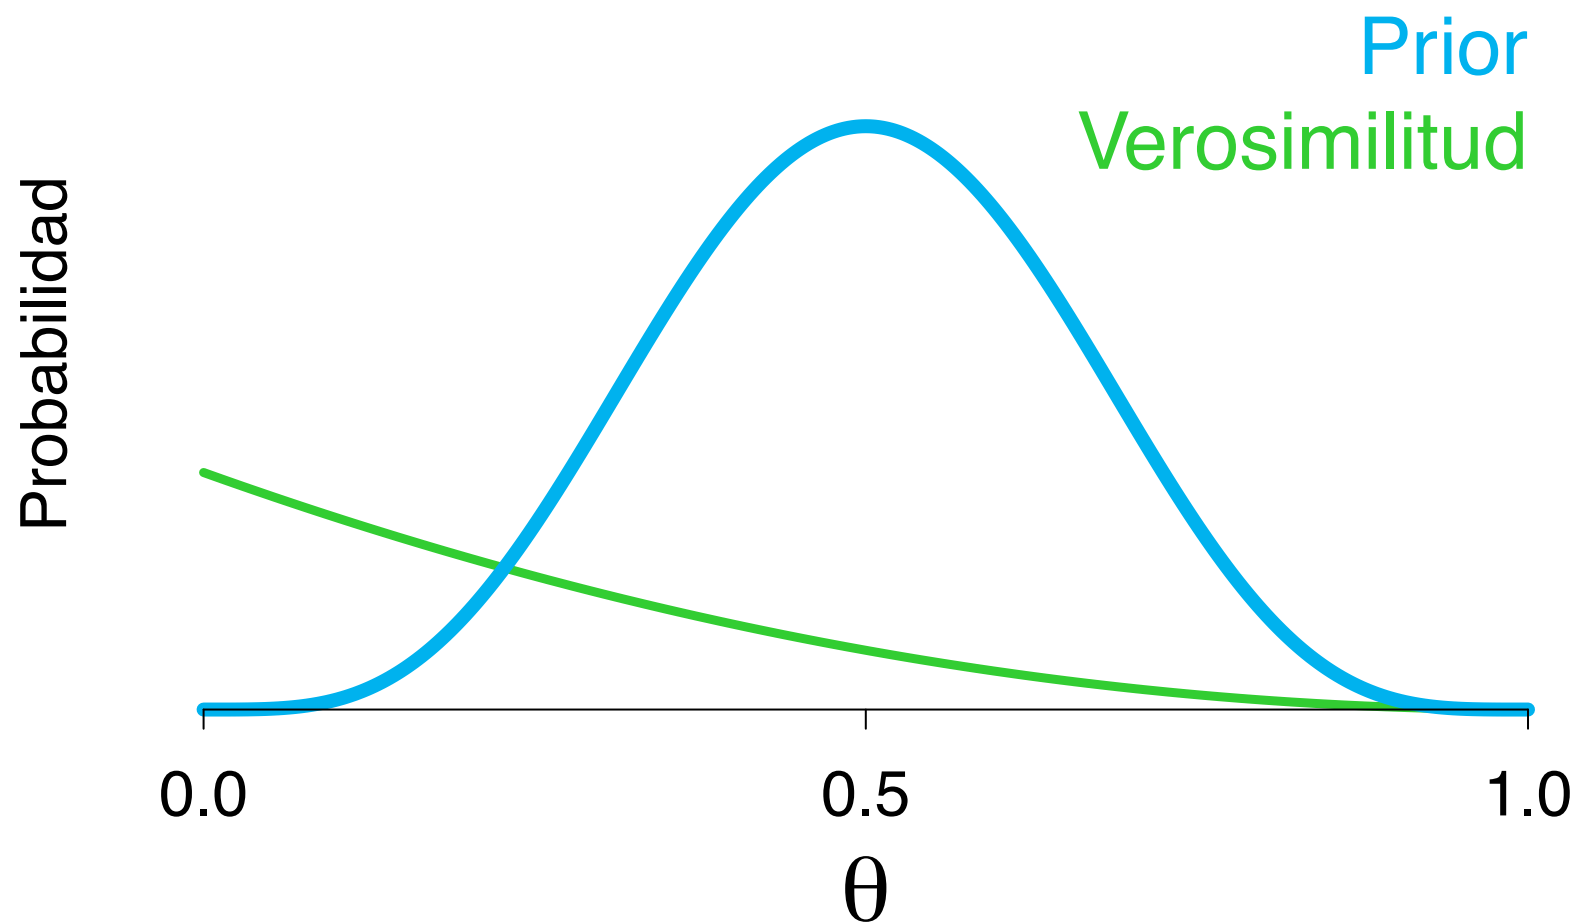
Secuencia 1:

$X \leftarrow [0 \ 0 \]$




Secuencia 1:

$X \leftarrow [0 \ 0 \]$



Secuencia 1:

$X \leftarrow [0 \ 0 \]$




Secuencia 2:

```
X <- [ 0 0 1 0 1 0 0 1 1 1 0 ... ]
```

Secuencia 2:

```
X <- [ 0 0 1 0 1 0 0 1 1 1 0 ... ]
```




$$\theta \sim \text{Beta}(\alpha = 5, \beta = 5)$$

$$X_i \sim \text{Bernoulli}(\theta)$$

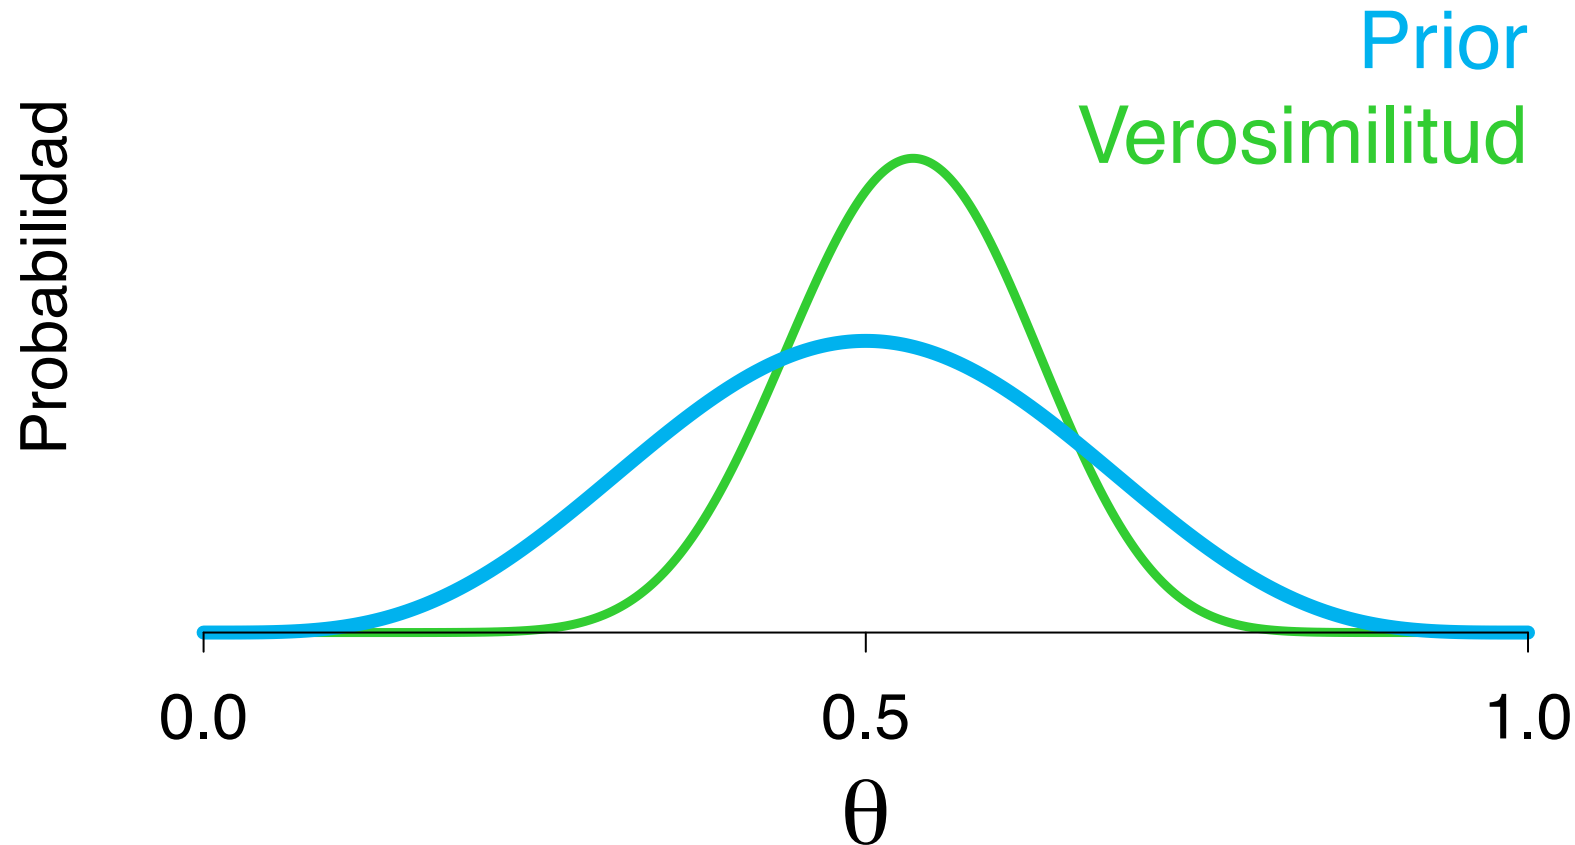
Secuencia 2:

$X \leftarrow [0 \ 0 \ 1 \ 0 \ 1 \ 0 \ 0 \ 0 \ 1 \ 1 \ 1 \ 0 \ \dots]$




Secuencia 2:

$X \leftarrow [0 \ 0 \ 1 \ 0 \ 1 \ 0 \ 0 \ 1 \ 1 \ 1 \ 0 \ \dots]$



Secuencia 2:

$X \leftarrow [0 \ 0 \ 1 \ 0 \ 1 \ 0 \ 0 \ 1 \ 1 \ 1 \ 0 \ \dots]$




Secuencia 3:

```
X <- [ 0 0 0 0 0 0 0 1 0 0 1 0 ... ]
```

Secuencia 3:

```
X <- [ 0 0 0 0 0 0 0 1 0 0 1 0 ... ]
```



$$\theta \sim \text{Beta}(\alpha = 5, \beta = 5)$$


$$X_i \sim \text{Bernoulli}(\theta)$$

Secuencia 3:

$X \leftarrow [0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 1 \ 0 \ 0 \ 1 \ 0 \ \dots]$


Prior

Probabilidad




Secuencia 3:

$X \leftarrow [0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 1 \ 0 \ 0 \ 1 \ 0 \ \dots]$



Secuencia 3:

$X \leftarrow [0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 0 \ 1 \ 0 \ 0 \ 1 \ 0 \ \dots]$



Podemos resolver los problemas de
selección de modelos y de
estimación paramétrica
utilizando los principios de
inferencia Bayesiana.

Ejemplo

Modelo de Decaimiento Exponencial

- Shiffrin, RM et al. (2008). *Cognitive Science*, 32, 1248-1284.


La probabilidad de recordar un item después de cierto tiempo:

$$\theta_t = \exp(-\alpha t) + \beta$$

α : Tasa de decaimiento

β : Línea base de recuerdo

[illegible]


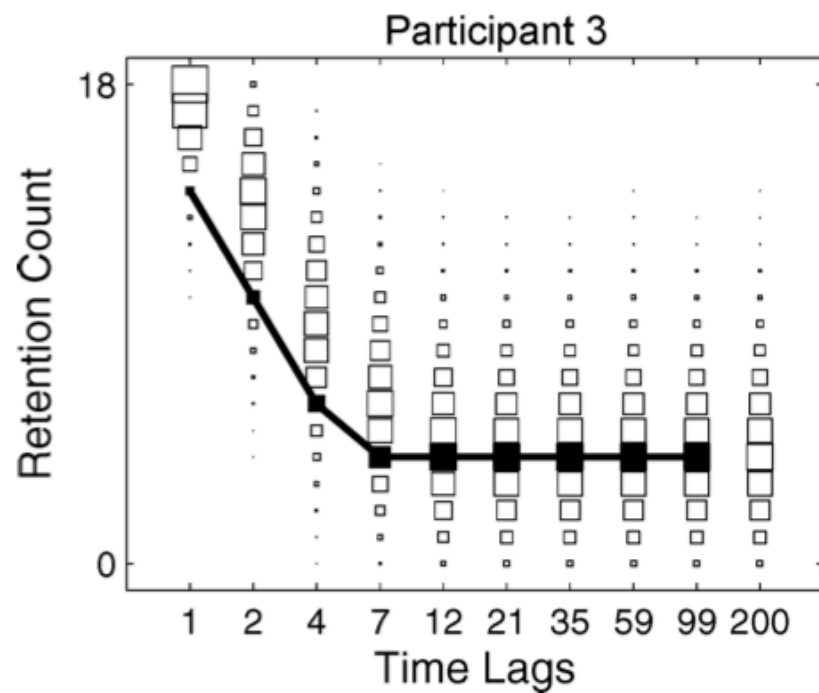
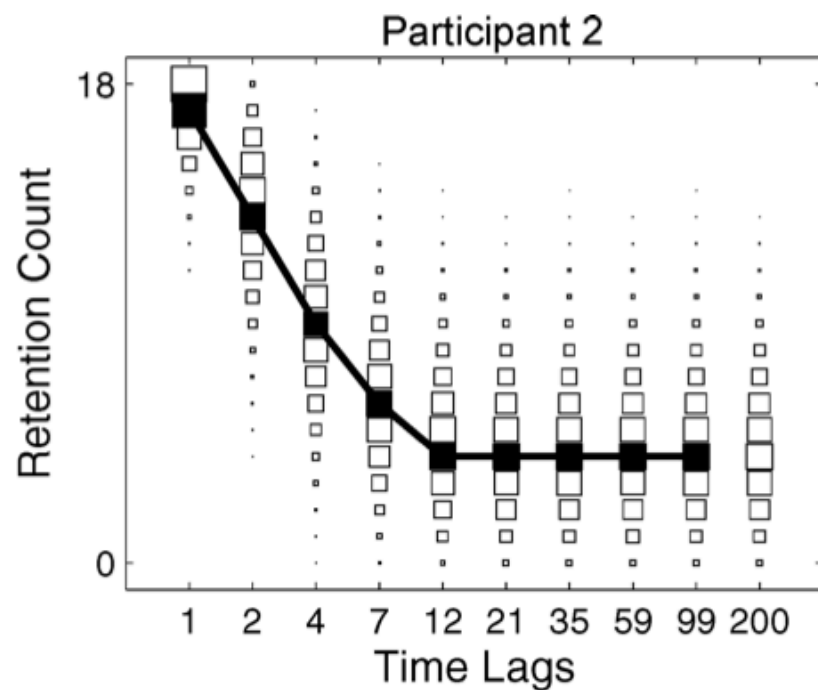




$$\alpha \sim \text{Uniform}(0, 1)$$

$$\beta \sim \text{Uniform}(0, 1)$$

$$\theta_j = \exp(-\alpha t_j) + \beta \quad 0 < \theta_j < 1$$

$$k_{ij} \sim \text{Binomial}(\theta_j, n_{ij})$$



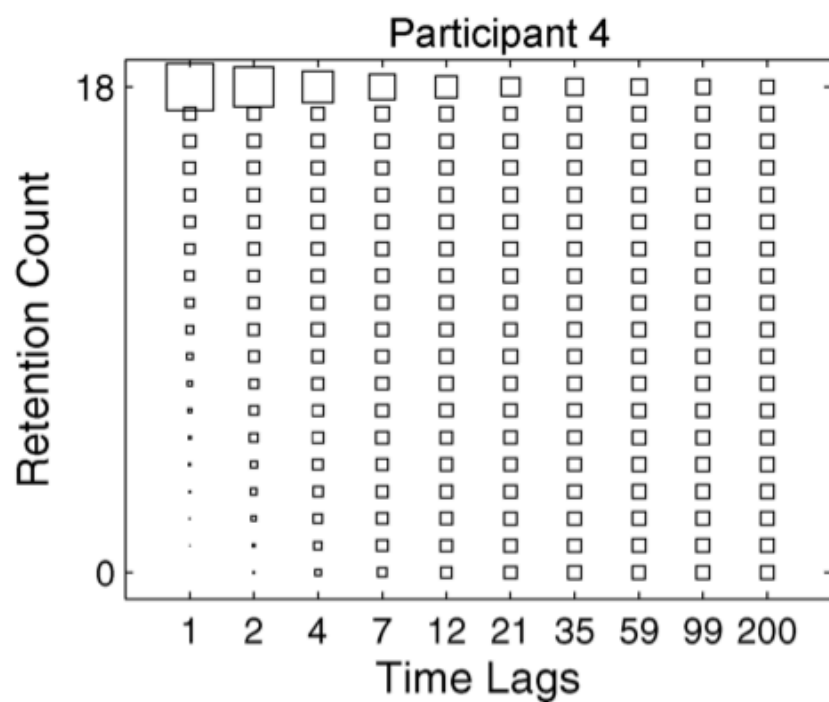
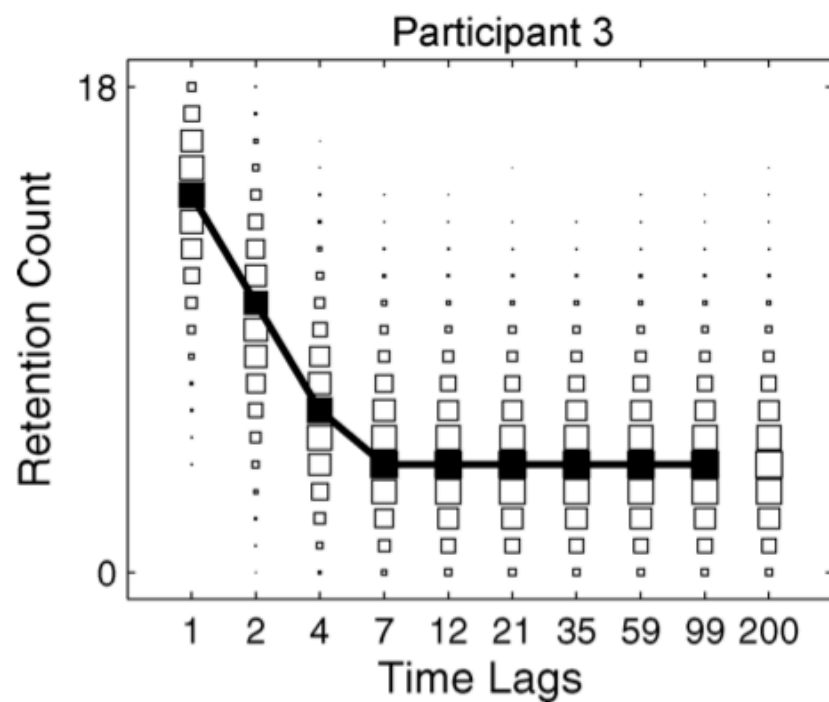




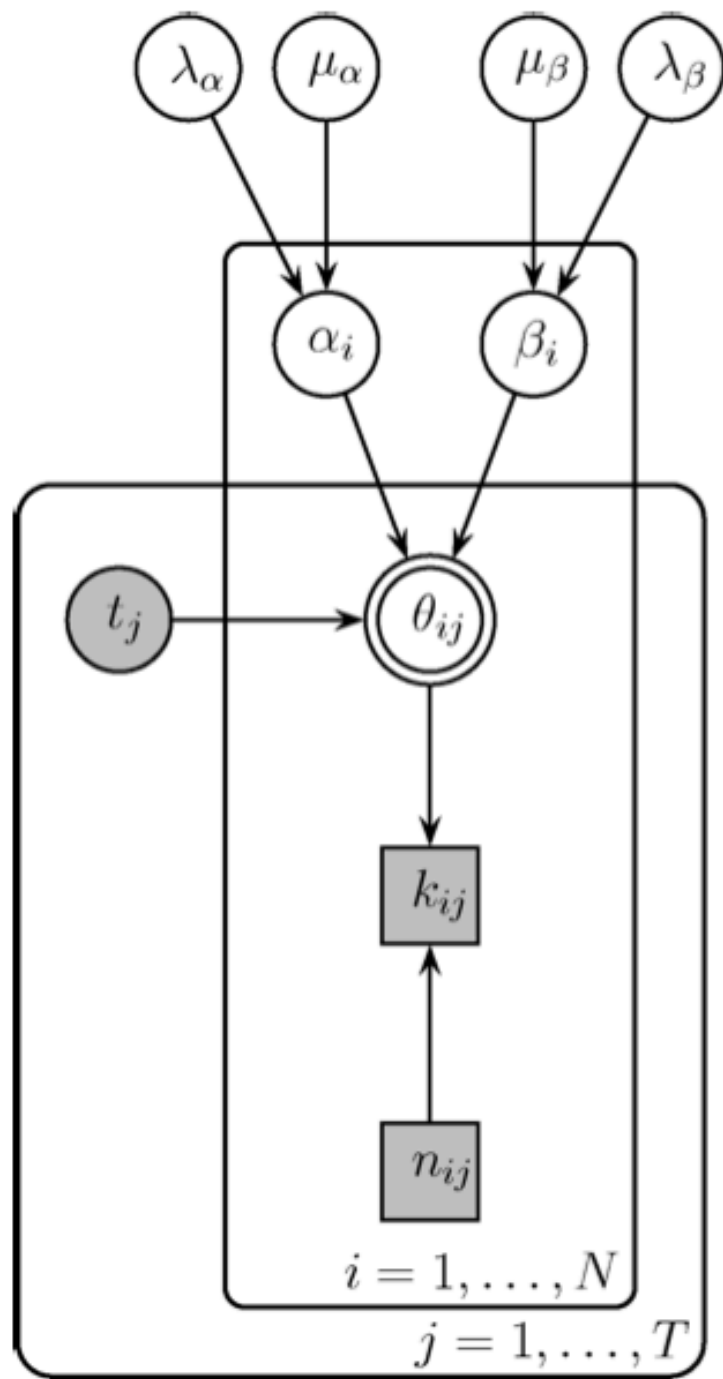
$$\alpha_i \sim \text{Uniform}(0, 1)$$

$$\beta_i \sim \text{Uniform}(0, 1)$$

$$\theta_{ij} = \exp(-\alpha_i t_j) + \beta_i \quad 0 < \theta_j < 1$$

$$k_{ij} \sim \text{Binomial}(\theta_{ij}, n_{ij})$$





$$\mu_\alpha \sim \text{Uniform}(0, 1)$$

$$\lambda_\alpha \sim \text{Gamma}(.001, .001)$$

$$\mu_\beta \sim \text{Uniform}(0, 1)$$

$$\lambda_\beta \sim \text{Gamma}(.001, .001)$$

$$\alpha_i \sim \text{Gaussian}(\mu_\alpha, \lambda_\alpha) \quad 0 < \alpha_i < 1$$

$$\beta_i \sim \text{Gaussian}(\mu_\beta, \lambda_\beta) \quad 0 < \beta_i < 1$$

$$\theta_{ij} = \exp(-\alpha_i t_j) + \beta_i \quad 0 < \theta_{ij} < 1$$

$$k_{ij} \sim \text{Binomial}(\theta_{ij}, n_{ij})$$

